

Implementasi Metode Ensemble Learning untuk Deteksi Dini Risiko Diabetes Melitus Berbasis Indikator Gaya Hidup

Cinta Angelika Putri¹, Fajar Adhitya Manthey², Feriza Heriyansyah³, ⁴Ospaldo AlpaginSelko Ginting⁴

Informatika, Universitas Satya Terra Bhinneka

Email: ¹cintaangelikaputri01@gmail.com, ²fajaradhitya925@gmail.com,

³ferizaheriyansyah6@gmail.com,

⁴ospaldoalpaginselkoginting@gmail.com

Abstract: Diabetes Mellitus (DM) is a chronic disease with a continuously increasing prevalence, necessitating accurate early detection to prevent serious complications. This study aims to perform a comparative evaluation of ensemble learning-based machine learning models (Gradient Boosting and Random Forest) alongside a linear approach (Logistic Regression) in predicting diabetes risk using clinical data and lifestyle patterns. The dataset comprises 70,692 samples with 14 input features, featuring a perfectly balanced label distribution (50% healthy and 50% diabetes). Following the CRISP-DM framework, the dataset was split using an 80:20 ratio for the training and testing phases, and further validated using K-Fold Cross-Validation. Experimental results demonstrate that the **Gradient Boosting** algorithm delivers the most optimal performance, achieving an accuracy of 74.00%, a consistent Cross-Validation Accuracy of 73.46%, and a ROC-AUC score of 0.8098 (indicating good classification). In the context of medical screening, Gradient Boosting recorded the highest Recall value at 77.71%, successfully capturing 5,493 True Positive cases within the confusion matrix. Feature importance analysis revealed that direct clinical markers, such as High Blood Pressure (contribution weight of 0.4264) and BMI (0.1832), serve as the most dominant determinants in the model's decision-making compared to lifestyle variables. This study concludes that the Gradient Boosting model possesses reliable safety and holds substantial potential for application as a clinical decision support system for early diabetes risk screening.

Keyword: *Ensemble Learning, Diabetes Mellitus, Early Detection, Lifestyle Indicators, Machine Learning, Risk Prediction*

Abstrak: Diabetes Melitus (DM) merupakan penyakit kronis dengan prevalensi yang terus meningkat, sehingga memerlukan deteksi dini yang akurat guna mencegah komplikasi serius. Penelitian ini bertujuan untuk melakukan evaluasi komparatif terhadap model *machine learning* berbasis *ensemble learning* (Gradient Boosting dan Random Forest) serta pendekatan linier (Logistic Regression) dalam memprediksi risiko diabetes menggunakan data klinis dan pola gaya hidup. Dataset yang digunakan mencakup 70.692 sampel dengan 14 fitur input, yang memiliki proporsi label seimbang (50% sehat dan 50% diabetes). Metode penelitian mengikuti kerangka kerja CRISP-DM dengan pembagian data menggunakan rasio 80:20 untuk fase pelatihan dan pengujian, serta divalidasi menggunakan *K-Fold Cross-Validation*. Hasil eksperimen menunjukkan bahwa algoritma Gradient Boosting memberikan performa paling optimal dengan tingkat akurasi sebesar 74,00%, stabilitas *Cross-Validation Accuracy* yang konsisten sebesar 73,46%, dan skor ROC-AUC mencapai 0,8098 (*good classification*). Pada konteks skrining medis, Gradient Boosting mencatatkan nilai *Recall* tertinggi sebesar 77,71% dengan kemampuan menjaring 5.493 kasus *True Positive* pada matriks kekacauan (*confusion matrix*). Analisis tingkat kepentingan fitur (*feature importance*) mengungkap bahwa indikator klinis langsung seperti Tekanan Darah Tinggi (bobot kontribusi 0,4264) dan BMI (0,1832) menjadi faktor penentu paling dominan dalam keputusan model dibandingkan variabel gaya hidup. Penelitian ini menyimpulkan bahwa model Gradient Boosting memiliki reliabilitas yang aman dan sangat potensial diaplikasikan sebagai sistem penunjang keputusan medis untuk skrining awal risiko diabetes.

Kata kunci: *Ensemble Learning, Diabetes Melitus, Deteksi Dini, Indikator Gaya Hidup, Machine Learning, Prediksi Risiko*

PENDAHULUAN

Diabetes Mellitus (DM) merupakan salah satu penyakit kronis yang prevalensinya terus meningkat, terutama di negara berkembang. Menurut Organisasi Kesehatan Dunia (WHO), DM menjadi penyebab utama kematian dan berbagai komplikasi serius, termasuk penyakit kardiovaskular, kerusakan saraf, dan gagal ginjal. Identifikasi dini terhadap faktor risiko DM sangat penting untuk pencegahan dan pengelolaan penyakit ini, terutama di komunitas pedesaan yang memiliki akses terbatas terhadap layanan kesehatan. Sebagai upaya peningkatan kesehatan masyarakat, menekankan pentingnya skrining DM di komunitas pedesaan untuk deteksi dini dan intervensi yang tepat waktu. Program skrining berbasis komunitas tersebut terbukti dapat meningkatkan kesadaran masyarakat terhadap risiko DM serta mendorong perubahan gaya hidup yang lebih sehat. Selain itu, juga menegaskan bahwa edukasi masyarakat mengenai prevalensi dan faktor risiko diabetes sangat berperan dalam meningkatkan pengetahuan dan kesiapsiagaan masyarakat dalam melakukan upaya pencegahan sejak dini. Meskipun pendekatan ini efektif dari sisi edukatif dan preventif, metode konvensional masih memiliki keterbatasan dalam akurasi prediksi dan efisiensi operasional.

Sejalan dengan perkembangan teknologi informasi, berbagai penelitian telah dilakukan untuk mengembangkan model prediksi berbasis machine learning (ML) guna membantu dalam identifikasi faktor risiko DM. Model berbasis ML memiliki keunggulan dalam menangani data berukuran besar dan kompleks, serta meningkatkan akurasi prediksi dibandingkan metode statistik tradisional. Sebagai contoh, mengembangkan model prediksi DM menggunakan teknik stacking ensemble berbasis Convolutional Gated Recurrent Neural Network(CGRNN), yang efektif dalam mengolah data sekuensial.

Selain itu, penelitian lain seperti memperkenalkan metode En-RfRsK, yang menggabungkan model Random Forest dengan teknik ensemble lainnya untuk meningkatkan performa prediksi. Pendekatan stacking ensemble juga diadopsi oleh yang menemukan bahwa kombinasi beberapa model dapat meningkatkan akurasi diagnosis.

mengusulkan kerangka kerja praktis menggunakan beragam model ensemble, sedangkan memanfaatkan model tri-ensemble dengan fitur yang telah diimputasi untuk hasil prediksi yang lebih baik.

Penelitian ini memiliki beberapa keunggulan dibandingkan studi-studi sebelumnya dalam bidang prediksi risiko Diabetes Mellitus (DM), penelitian ini membandingkan berbagai teknik ensemble learning—yaitu Bagging, Boosting (seperti AdaBoost dan Gradient Boosting), Stacking, dan Voting. Pendekatan ini memberikan gambaran yang lebih menyeluruh tentang efektivitas masing-masing metode dalam meningkatkan akurasi dan stabilitas prediksi.

Meskipun banyak pendekatan ensemble telah dikembangkan, masih terdapat kesenjangan dalam literatur terkait evaluasi komparatif antar teknik ensemble seperti bagging, boosting, dan stacking, terutama dalam konteks generalisasi model terhadap dataset yang beragam dan kompleks. Selain itu, aspek interpretabilitas model masih kurang diperhatikan, padahal sangat krusial dalam aplikasi klinis guna memastikan kepercayaan dan adopsi oleh praktisi kesehatan. Penelitian ini bertujuan untuk mengisi gap tersebut melalui: Evaluasi komparatif antara teknik bagging, boosting, dan stacking dalam prediksi faktor risiko DM; Analisis generalisasi model terhadap berbagai jenis dataset (global dan lokal); dan Kajian terhadap interpretabilitas model dalam konteks aplikasi klinis.

METODE

Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimental. Penelitian dilakukan dengan mengeksplorasi data sekunder untuk membangun model prediksi (machine learning) tanpa melibatkan pengembangan antarmuka aplikasi. Kerangka kerja yang digunakan dalam riset ini mengikuti tahapan standar CRISP-DM (Cross-Industry Standard Process for Data Mining), yang meliputi pemahaman data, persiapan data, pemodelan, dan evaluasi.

Dataset berhasil dimuat!
 Ukuran dataset : 78,652 baris x 15 kolom

	Status Diabetes	Glukosa Darah Tinggi	Kolesterol Tinggi	Asam Perak	Risiko Stroke	Risiko Penyakit Jantung	Aktivitas Fisik Rutin	Konsumsi Buah Harian	Konsumsi Sayur Harian	Konsumsi Alkohol Tinggi	Kesehatan Fisik	Kesulitan Berjalan	Jenis Kelamin	usia
0	0	1	0	20	0	0	1	0	1	0	30	0	1	4
1	0	1	1	20	1	1	0	1	0	0	0	0	1	12
2	0	0	0	20	0	0	1	1	1	0	10	0	0	1
3	0	1	1	20	1	0	0	1	1	0	3	0	1	11
4	0	0	0	20	1	0	0	1	1	1	0	0	0	8

Metode penelitian ini dilakukan melalui pendekatan eksperimental *machine learning* dengan menggunakan dataset skrining kesehatan yang mencakup 70.692 baris data dan 15 kolom variabel. Variabel 'Status Diabetes' diposisikan sebagai variabel target berbentuk biner (nilai 0 untuk sehat dan 1 untuk risiko diabetes). Sementara itu, 14 variabel lainnya digunakan sebagai prediktor yang meliputi indikator klinis, riwayat medis, faktor demografi, serta pola gaya hidup pasien.

```
=====
DISTRIBUSI LABEL (Status Diabetes)
=====
Non-Diabetes (0) : 35,346 data (50.0%)
Diabetes (1) : 35,346 data (50.0%)

Total Data : 70,692
```

Hasil statistik deskriptif terhadap 70.692 data menunjukkan bahwa dataset ini seimbang sempurna, dengan proporsi pasien sehat dan berisiko diabetes masing-masing sebesar 50% (35.346 data). Dari sisi klinis, mayoritas subjek memiliki faktor risiko tinggi: 56% mengalami hipertensi, 53% memiliki kolesterol tinggi, dan rata-rata BMI berada di angka 29,86 (ambang batas obesitas). Sementara dari aspek demografi dan kebiasaan, subjek didominasi kelompok usia paruh baya hingga lansia (rata-rata skala 8,58), dengan 48% di antaranya merupakan perokok aktif dan 70% rutin beraktivitas fisik. Kelengkapan indikator klinis dan pola hidup ini menjadi modal kuat bagi algoritma untuk mengenali pola risiko diabetes secara objektif.

```
★ Mapping kode Usia:
Kode 1 → 18-24 tahun
Kode 2 → 25-29 tahun
Kode 3 → 30-34 tahun
Kode 4 → 35-39 tahun
Kode 5 → 40-44 tahun
Kode 6 → 45-49 tahun
Kode 7 → 50-54 tahun
Kode 8 → 55-59 tahun
Kode 9 → 60-64 tahun
Kode 10 → 65-69 tahun
Kode 11 → 70-74 tahun
Kode 12 → 75-79 tahun
Kode 13 → 80+ tahun

✓ Jumlah fitur input : 14
✓ Jumlah sampel : 70,692
✓ Distribusi label : {0: np.int64(35346), 1: np.int64(35346)}

Data Training : 56,553 sampel
Data Testing : 14,139 sampel

✓ Preprocessing selesai! Data siap digunakan.
```

Pada tahap Preprocessing, variabel usia dikelompokkan ke dalam 13 kategori skala ordinal mulai dari 18–24 tahun hingga 80 tahun ke atas. Dataset ini memiliki 14 fitur input dengan total 70.692 data, yang proporsi labelnya sudah seimbang sempurna (masing-masing

35.346 sampel untuk kelas sehat dan diabetes) guna mencegah bias klasifikasi. Terakhir, data dipecah dengan rasio 80:20, menghasilkan 56.553 data latih (*Data Training*) untuk membangun model dan 14.139 data uji (*Data Testing*) untuk evaluasi performa akhir.


HASIL DAN PEMBAHASAN

TABEL PERBANDINGAN PERFORMA MODEL KLASIFIKASI							
	Model	Accuracy	Precision	Recall	F1-Score	ROC-AUC	CV Accuracy
1	Gradient Boosting	0.7400	0.7234	0.7771	0.7493	0.8098	0.7346
2	Logistic Regression	0.7331	0.7251	0.7507	0.7377	0.8046	0.7324
3	Random Forest	0.7061	0.6973	0.7284	0.7125	0.7612	0.6993


MODEL TERBAIK : Gradient Boosting	
Accuracy	: 0.7400
F1-Score	: 0.7493
ROC-AUC	: 0.8098
CV Accuracy	: 0.7346

Berdasarkan hasil eksperimen pemodelan klasifikasi deteksi dini Diabetes Melitus terhadap tiga algoritma (Tabel X), Gradient Boosting menunjukkan performa paling optimal dibandingkan Logistic Regression dan Random Forest. Model Gradient Boosting menghasilkan tingkat akurasi sebesar 74,00% dengan nilai validasi silang (*Cross-Validation Accuracy*) sebesar 73,46%, yang mengindikasikan konsistensi performa model yang stabil tanpa indikasi *overfitting*.

Pada konteks skrining medis, kemampuan model dalam menjangkau penderita diabetes secara tepat menjadi prioritas utama yang direpresentasikan oleh nilai *Recall* (Sensitivitas). Model Gradient Boosting berhasil mencatatkan nilai *Recall* tertinggi sebesar 77,71%, dipadukan dengan nilai area di bawah kurva karakteristik operasi penerima (*ROC-AUC*) sebesar 0,8098. Nilai AUC yang berada pada rentang 0,8 - 0,9 ini menegaskan bahwa model Gradient Boosting memiliki klasifikasi yang baik (*good classification*) dalam membedakan subjek berisiko diabetes dan non-diabetes.




Berdasarkan grafik **Gradient Boosting** (yang ditandai dengan garis tepi merah tebal pada grafik) adalah **model terbaik** dalam eksperimen ini karena mendominasi seluruh metrik pengujian. Struktur algoritma *boosting* yang memperbaiki kesalahan prediksi pohon keputusan secara bertahap terbukti lebih adaptif pada pola data dataset diabetes ini dibandingkan metode *bagging* (Random Forest) maupun pendekatan linier (Logistic Regression).



Berdasarkan grafik *Confusion Matrix* pada Gambar X, performa deteksi dari model Gradient Boosting dapat dibedah secara lebih mendalam. Hasil pengujian menunjukkan performa yang solid dengan keberhasilan menebak secara akurat sebanyak 5.493 kasus positif diabetes (*True Positive*) dan 4.970 kasus subjek sehat (*True Negative*).

Meskipun demikian, sistem masih menyisakan margin error berupa 2.100 kasus *False Positive* dan 1.576 kasus *False Negative*. Dalam implementasi klinis, menekan angka *False Negative* merupakan prioritas krusial untuk menghindari risiko keterlambatan penanganan pada pasien diabetes yang tidak terdeteksi. Mengingat jumlah prediksi benar (*True Positive*) jauh lebih mendominasi dibandingkan angka kebocoran prediksi (*False Negative*), model Gradient Boosting ini dinilai memiliki tingkat reliabilitas yang aman dan sangat potensial diaplikasikan sebagai sistem penunjang keputusan medis untuk skrining awal.



Berdasarkan grafik *Feature Importance* pada Gambar X, kita bisa melihat faktor klinis apa saja yang paling memengaruhi keputusan model dalam mendeteksi risiko diabetes. Kedua algoritma, baik Random Forest maupun Gradient Boosting, sama-sama menempatkan variabel BMI, Usia, dan Tekanan Darah Tinggi sebagai tiga indikator teratas. Pada model Gradient Boosting yang merupakan model terbaik, faktor Tekanan Darah Tinggi menjadi penentu paling kuat dengan bobot nilai kepentingan mencapai 0,4264, disusul oleh BMI sebesar 0,1832.

Sebaliknya, variabel yang berkaitan dengan perilaku atau gaya hidup, seperti konsumsi buah, konsumsi sayur, dan kebiasaan merokok, justru berada di posisi terbawah dengan kontribusi di bawah 3%. Secara medis, hal ini menunjukkan bahwa model lebih memprioritaskan kondisi klinis yang sifatnya dampak langsung (*direct clinical markers*) seperti obesitas (BMI) dan hipertensi yang sudah menetap pada tubuh pasien, ketimbang faktor eksternal yang sifatnya tidak langsung.

SIMPULAN

Berdasarkan Penelitian ini menunjukkan bahwa model prediktif berbasis *boosting* lebih adaptif dan andal dalam memproses data skrining diabetes dibandingkan metode linier tradisional maupun teknik *bagging*. Kontribusi ilmiah utamanya terletak pada penyelarasan akurasi model dengan logika klinis lewat analisis bobot fitur, yang membuktikan bahwa algoritma secara otomatis memprioritaskan indikator klinis langsung (hipertensi dan obesitas) di atas variabel gaya hidup tidak langsung. Secara praktis, model ini sangat potensial diintegrasikan sebagai penunjang keputusan klinis di fasilitas kesehatan tingkat pertama untuk mempercepat penyaringan awal pasien berisiko. Ke depan, kerangka kerja ini dapat dikembangkan melalui pengujian dataset lokal yang lebih spesifik atau dikombinasikan dengan teknik *deep learning* untuk mengolah

rekam medis elektronik tidak terstruktur agar deteksi dini berjalan lebih dinamis dan personal.

DAFTAR PUSTAKA

- Agustina, A. R., Pratama, M. R., Yunus, M., & Rachmawati, E. (t.t.). *Sistem Deteksi Dini Diabetes Melitus Dengan Teknik Klasifikasi Algoritma C4.5 Berdasarkan Rekam Medis di RS Tk. III Baladhika Husada Jember*.
- Arini, F. Y., Oktavian, A., Aldevis, M. F., Aryaputra, D. P., & Hidja, A. (t.t.). *Kolaborasi Algoritma K-Nearest Neighbor Dan Gradient Boosting Untuk Klasifikasi Diabetes Melitus Tipe 2*. 15(3).
- Fachmi, A. N., Patria, R. D., Ramadhan, F. R., Pudjiati, S., & Sari, A. P. (2026). *Perbandingan Kinerja Klasifikasi Data Mining untuk Diagnosis Diabetes*. 7(1).
- Gunawan, S., Astuti, R., Prihartono, W., & Hamonangan, R. (2025). PREDIKSI DIABETES MELLITUS TIPE 2 DENGAN ALGORITMA LOGISTIC REGRESSION UNTUK PENDETEKSIAN DINI. *Jurnal Informatika dan Teknik Elektro Terapan*, 13(1). <https://doi.org/10.23960/jitet.v13i1.5747>
- Hidayat, J. J., Saputra, M. R., Sigand, A. R., Fadilah, A. L. N., Amin, M. D. I., & Rizki, A. (2026). *Evaluasi Kinerja Algoritma Ensemble Learning Pada Klasifikasi Penyakit Diabetes Berbasis Boosting Method*. 16(1).
- Ijayanti, S., & Utomo, D. W. (t.t.). *Implementasi Stacking Ensemble Berbasis Cross Domain untuk Klasifikasi Diabetes*.
- Khairunnisa, R. D., Witanti, W., & Komarudin, A. (2026). *PENERAPAN ALGORITMA MACHINE LEARNING UNTUK PREDIKSI PENYAKIT DIABETES MILITUS MENGGUNAKAN METODE EXTREME GRADIENT BOOSTING*. 11(2).
- Pratama, N. A., & Utomo, D. W. (t.t.). *Deteksi Diabetes Mellitus dengan Menggunakan Teknik Ensemble XGBoost dan LightGBM*.
- Putri, P. R., & Alit, R. (2024). *Klasifikasi Penyakit Diabetes Melitus Menggunakan Metode Support Vector Machine (SVM)*. 06.
- Ruziq, F., Wayahdi, M. R., Kom, S., & Kom, M. (t.t.). *PREDIKSI RISIKO DIABETES DINI BERBASIS K-NEAREST NEIGHBORS (K-NN): STUDI IMPLEMENTASI PADA PLATFORM WEB*.
- Sidiq, S., & Maburur, N. S. (2025). *Pengembangan Model Prediksi Risiko Diabetes Menggunakan Pendekatan AdaBoost dan Teknik Oversampling SMOTE*. 4.
- Syaban, K. & Mardawati. (2025). Evaluasi Model Ensemble Learning pada Identifikasi Faktor Risiko Diabetes Mellitus. *Jurnal Teknologi dan Informasi*, 15(2), 121–130. <https://doi.org/10.34010/jati.v15i2.16238>
- Wibisono, S., Hadikurniawati, W., Yulianton, H., Lestariningsih, E., & Cahyono, T. D. (2024). *Optimalisasi Model Klasifikasi Diabetes Menggunakan Ensemble Learning Adaboost, Gradient Boosting, dan XGBoost*. 09.
- Yunitasari, A. A., Pratama, M. R., Yunus, M., & Suyoso, G. E. J. (t.t.). *Sistem Deteksi Dini Diabetes Mellitus Berdasarkan Rekam Medis Menggunakan Algoritma K-Nearest Neighbor*.